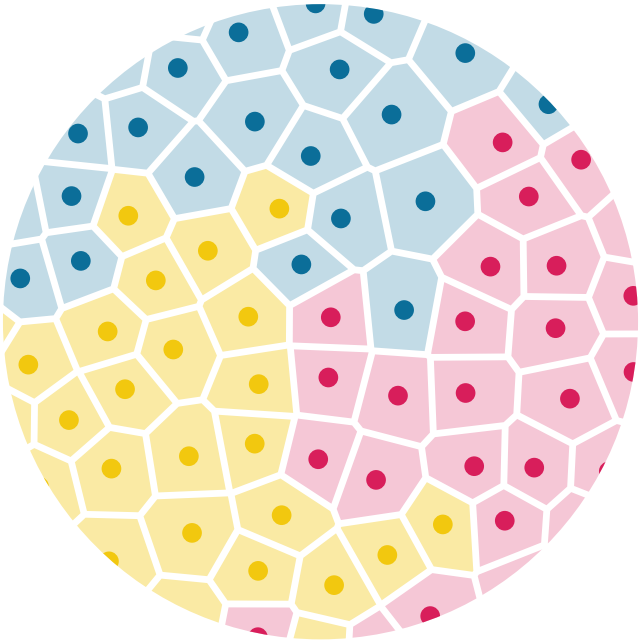
Школьный этап

Серия 1



Как сдавать

Все виды задач тура: с ответом, на данные и программы. Сдача — через `kontest.py` в папке `kontest`, подробно — в его `README.md`. Архив с проверкой и установка — на сайте `conduit-admin.github.io/vsosh-ii`. Пункт а) сдаётся как `1a`, б) — `1b`, в) — `1c`:

```
python kontest.py 1a 5/8
python kontest.py 12b answer.csv
python kontest.py 13 reshenie.py
python kontest.py itog
```

У задачи с ответом засчитывается последняя посылка, у программы — лучшая. Файлы к задачам 10–12 лежат в `kontest/seriya-01/dannye/`. Программа читает стандартный ввод и пишет в стандартный вывод.

Вероятность

1 (Голосование моделей). Пять моделей независимо друг от друга решают, есть ли на снимке кошка. Первая и вторая отвечают верно с вероятностью $\frac{3}{5}$, третья и четвёртая — $\frac{7}{10}$, пятая — $\frac{4}{5}$. Итоговый ответ выбирается большинством голосов.

а) С какой вероятностью итоговый ответ верен?

б) Одну модель убирают, а при ничьей 2:2 ответ решает честная монета. Какую наибольшую вероятность верного итогового ответа можно получить, выбирая, какую модель убрать?

Ответ: несократимая дробь.

2 (Перемешанные метки). В выборке 10 объектов: 6 класса 1 и 4 класса 0. «Модель» берёт настоящие метки и выдаёт их в случайном порядке: все перестановки меток равновероятны.

а) Найдите математическое ожидание accuracy этой модели.

б) С какой вероятностью accuracy окажется не меньше 0,8?

Ответ: несократимая дробь.

3 (Два фильтра). Среди писем $\frac{1}{5}$ — спам. Фильтр помечает спам с вероятностью $\frac{9}{10}$, а обычное письмо ошибочно помечает с вероятностью $\frac{1}{20}$.

а) Письмо помечено. С какой вероятностью это спам?

б) Каждое письмо проверяют два таких фильтра; при известном классе письма они ошибаются независимо. Оба пометили письмо. С какой вероятностью это спам?

в) Первый фильтр письмо пометил, второй — нет. С какой вероятностью это спам?

Ответ: несократимая дробь.

Метрики

4 (Диапазон F1). Классификатор проверили на 1000 объектах, из них 300 положительных. Его accuracy равна 0,85. Напомним:

$$F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2\,TP}{2\,TP + FP + FN}.$$

а) Какое наименьшее значение может принимать F_1?

б) Какое наибольшее?

Ответ: несократимая дробь.

5 (ROC-AUC и порог). Модель выдала оценки девяти объектам. Положительные объекты получили оценки 0,9; 0,7; 0,55; 0,3, отрицательные — 0,8; 0,55; 0,4; 0,2; 0,1.

а) Найдите ROC-AUC — долю пар «положительный, отрицательный», в которых у положительного оценка больше; пара с равными оценками даёт $\frac{1}{2}$. Ответ — несократимая дробь.

б) Объект считается положительным, если его оценка не меньше порога t. Порог выбирают среди оценок объектов. При каком t значение F_1 наибольшее? Ответ — десятичная дробь.

в) Чему равно это наибольшее F_1? Ответ — несократимая дробь.

Модели руками

6 (Соседи без себя). На плоскости 12 точек двух классов.

№	x	y	класс
1	4	4	B
2	7	7	B
3	0	1	A
4	2	2	A
5	7	2	B
6	5	2	A

№	x	y	класс
7	5	5	B
8	3	3	A
9	2	3	A
10	4	2	A
11	8	6	B
12	7	4	B

Каждую точку по очереди убирают и предсказывают её класс по остальным одиннадцати методом k ближайших соседей: выбирается класс, которого среди k ближайших точек больше. При равных расстояниях ближе считается точка с меньшим номером.

а) Для $k = 1, 3, 5, 7$ найдите, сколько из 12 точек классифицированы верно, если расстояние евклидово.

б) То же для манхэттенского расстояния $|x_1 - x_2| + |y_1 - y_2|$.

Ответ: четыре целых числа через пробел, в порядке возрастания k.

7 (Пороги дерева). У двенадцати объектов один признак x и класс:

x	1	1	1	1	4	5	8	9	11	11	14	14
класс	0	0	1	0	0	1	1	1	0	0	0	0

а) Решающий пень делит выборку порогом t: объекты с $x < t$ идут налево, с $x > t$ — направо; t берут посередине между соседними различными значениями x. Неоднородность части — критерий Джини $G = 1 - p_0^2 - p_1^2$, где p_0 и p_1 — доли классов в ней, а качество разбиения — $\frac{n_\mathrm{L}}{n} G_\mathrm{L} + \frac{n_\mathrm{R}}{n} G_\mathrm{R}$. При каком t оно наименьшее? Ответ — десятичная дробь.

б) Дерево глубины 2 задаёт вопрос «$x \le t$?», затем в каждой из двух частей ещё один такой вопрос со своим порогом; в каждом из четырёх листьев стоит один класс. Пороги — любые числа. Какое наименьшее число ошибок такое дерево может сделать на этой выборке?

8 (k-средних руками). Даны числа 1, 2, 5, 6, 19, 23, 38, 41, 43, 44. Алгоритм k-средних с $k = 2$ стартует с центров $c_1 = 1$ и $c_2 = 23$. Шаг алгоритма: каждое число относят к ближайшему центру (при равенстве — к c_1), затем каждый центр заменяют средним своих чисел. Шаги повторяют, пока распределение чисел по кластерам не перестанет меняться.

а) Чему равна сумма квадратов расстояний от чисел до центров их кластеров, когда алгоритм остановится?

б) Какова наименьшая такая сумма среди всех разбиений этих чисел на два непустых кластера, если центр кластера — среднее его чисел?

Ответ: несократимая дробь.

9 (Векторы слов). Восемь слов записаны векторами:

король	$(6, 4, 0)$	принц	$(4, 3, -1)$
королева	$(6, -4, 1)$	принцесса	$(4, -3, 0)$
мужчина	$(1, 5, 1)$	яблоко	$(0, 0, 7)$
женщина	$(1, -5, 1)$	груша	$(-1, 1, 6)$

Близость слов — косинус угла между их векторами.

а) Какие два слова ближе всего друг к другу? Ответ — два слова через пробел.

б) Вычислите вектор *король* $-$ *мужчина* $+$ *женщина*. Какое слово, кроме этих трёх, ближе всего к нему? Ответ — слово.

Данные

10 (Журнал доставки). Файл `dostavka.csv` — заказы службы доставки: номер заказа, город, вес в килограммах, время доставки в часах, оценка клиента от 1 до 5. Файл выгрузили из Excel; часть полей заполняли вручную.

а) Удалите заказы, время доставки которых не попадает в отрезок от 1 до 72 часов включительно. Сколько заказов осталось?

б) В оставшихся заказах пустые оценки замените медианой оценок того же города. Найдите среднюю оценку по всем оставшимся заказам. Ответ округлите до тысячных.

в) В каком городе по оставшимся заказам самый большой средний вес заказа? Ответ — название города.

11 (Датчик). Файл `datchik.csv`: датчик температуры раз в 10 минут присылает время и значение. Связь ненадёжная: часть отметок потерялась, часть пришла дважды, строки в файле перемешаны. Значение -999 значит, что датчик ответил ошибкой, пустое поле — что значения нет. Полностью одинаковые строки считайте одной.

а) Сколько различных моментов времени есть в файле?

б) Сколько 10-минутных отметок между первой и последней, включая их самих, в файле нет?

в) В какой день средняя температура, без ошибок и пустых значений, наибольшая? Ответ — дата вида `2026-09-05`.

12 (Ученики и баллы). Два файла. В `ucheniki.csv` — номер ученика, фамилия и имя, класс. В `rezultaty.csv` — номер ученика, предмет, балл и номер попытки; «н/я» значит, что ученик не явился, это не балл. Номер ученика в двух файлах мог быть записан по-разному. В `rezultaty.csv` есть записи учеников, которых нет в `ucheniki.csv`, — их не учитывайте.

Лучший балл ученика по предмету — максимум по его попыткам. Итог ученика — среднее его лучших баллов по тем предметам, где они есть.

а) Сколько учеников из `ucheniki.csv` не имеют ни одной записи в `rezultaty.csv`?

б) Для каждого класса найдите среднее итогов его учеников; ученики без единого балла не учитываются. Сдайте файл `answer.csv` с заголовком `klass,sredniy` и строкой на каждый класс, среднее округлите до сотых.

в) Для каждого предмета найдите среднее m и стандартное отклонение σ лучших баллов по нему; в σ делят на число учеников, а не на число минус один. Сколько пар «ученик, предмет», в которых лучший балл больше $m + 2\sigma$?

Программы

Тестов у каждой задачи 20, балл — за каждый пройденный; примеры из условия баллов не дают. Ограничение времени — 1 секунда на тест на олимпиаде, 2 — в `kontest.py`.

13 (Лучший порог). У n объектов есть целая оценка модели s_i и настоящий класс y_i, 0 или 1. Классификатор с порогом t относит объект к классу 1, если $s_i \geq t$, иначе к классу 0. Порог выбирают среди чисел $s_1, \ldots, s_n$ и числа $\max_i s_i + 1$. Найдите наибольшее число верно классифицированных объектов и наименьший порог, на котором оно достигается.

Ввод. В первой строке n ($1 \leq n \leq 2 \cdot 10^5$), в каждой из следующих n строк — s_i и y_i ($|s_i| \leq 10^9$). В 13 тестах из 20 $n \leq 1000$.

Вывод. Два числа через пробел: наибольшее число верных ответов и наименьший порог.

Ввод	Вывод
5 3 1 1 0 4 1 1 1 5 0	3 1
4 -5 0 7 0 7 1 2 0	3 7

14 (Частые слова). Слово — наибольшая подряд идущая цепочка латинских букв; всё остальное, включая цифры, апостроф и дефис, слова разделяет. Большие и маленькие буквы не различаются. Выведите k самых частых слов с числом их появлений: по убыванию числа, при равенстве — по алфавиту. Если различных слов меньше k, выведите все.

Ввод. В первой строке k ($1 \le k \le 1000$), дальше до конца ввода — текст из нескольких строк, всего не больше $2 \cdot 10^6$ символов. В тексте только символы ASCII и хотя бы одно слово. В 12 тестах из 20 текст короче 50 000 символов.

Вывод. По строке на слово: слово маленькими буквами и число.

Ввод

```
3
The cat and the hat. THE END!
Cat-and-dog: 2cats?
```

Вывод

```
the 3
and 2
cat 2
```

Ввод

```
5
Don't stop... don't!
```

Вывод

```
don 2
t 2
stop 1
```

15 (Окно без выбросов). Дан ряд из n измерений $a_1, \ldots, a_n$ и число D. Найдите самый длинный отрезок подряд идущих измерений, в котором наибольшее и наименьшее различаются не больше чем на D. Если таких несколько, выберите самый левый.

Ввод. В первой строке n и D ($1 \le n \le 2 \cdot 10^5$, $0 \le D \le 10^9$), во второй — $a_1, \ldots, a_n$ ($|a_i| \le 10^9$). В 13 тестах из 20 $n \le 3000$.

Вывод. Длина отрезка и номер его первого элемента; нумерация с единицы.

Ввод	Вывод
8 3 5 1 3 4 6 2 2 9	3 2
5 0 7 7 1 1 1	3 3

16 (Ближайший сосед). На прямой n размеченных точек: i-я стоит в x_i и имеет класс c_i. Для каждого из q запросов z выведите класс ближайшей к z точки. Если две точки на одинаковом расстоянии — класс той, что левее.

Ввод. В первой строке n и q ($1 \le n, q \le 2 \cdot 10^5$), в следующих n строках — x_i и c_i ($|x_i| \le 10^9$, все x_i различны, $1 \le c_i \le 10^9$), в следующих q строках — запросы z ($|z| \le 10^9$). В 13 тестах из 20 $n, q \le 1000$.

Вывод. q строк — ответы на запросы по порядку.

Ввод	Вывод
3 4 0 1 10 2 4 3 2 7 -5 11	1 3 1 2