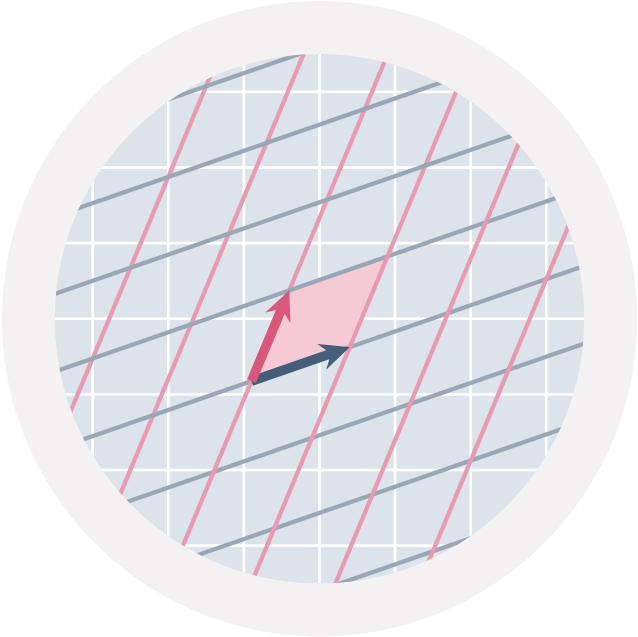
Матрицы как преобразования

Урок



Матрица — таблица чисел, но думать о ней лучше как о преобразовании: она берёт вектор и выдаёт вектор. Слой нейросети, поворот картинки, шаг по графу состояний — всё это матрицы. Каждая новая вещь здесь — на маленьком примере, короткие факты — с доказательством: приёмы оттуда пригодятся в задачах.

Векторы в уроке — столбцы, но в строке текста их пишут через запятую: $x = (3, 1)$ — это столбец из чисел 3 и 1. Все векторы длины n вместе обозначают $\mathbb{R}^n$.

1 Линейные преобразования

Объект в машинном обучении — набор чисел, вектор признаков. Отзыв о фильме можно описать двумя числами: x_1 — сколько в нём похвал, x_2 — сколько ругани. Отзыв «три похвалы, одна ругань» — вектор $x = (3, 1)$.

Слой нейросети без активации считает из входного вектора новый, и каждое выходное число — взвешенная сумма входных. Пусть слой выдаёт два числа:

$$y_1 = 2x_1 - 3x_2, \qquad y_2 = x_1 + x_2.$$

Первое — тон отзыва: похвала с весом 2, ругань с весом -3. Второе — сколько в отзыве оценок вообще. Отзыв $(3, 1)$ слой переводит в $(3, 4)$, отзыв $(1, 2)$ — в $(-4, 3)$.

Преобразование f из $\mathbb{R}^n$ в $\mathbb{R}^m$ называется *линейным*, если для любых векторов v, w и любого числа c

$$f(v + w) = f(v) + f(w), \qquad f(cv) = c\,f(v).$$

Слой выше линеен: отзыв $(3, 1) + (1, 2) = (4, 3)$ он переводит в $(-1, 7) = (3, 4) + (-4, 3)$, и так для любых векторов — каждая координата выхода — сумма слагаемых «вес на координату входа».

Из двух свойств следует общее: образ комбинации — та же комбинация образов,

$$f(c_1 v_1 + \cdots + c_k v_k) = c_1 f(v_1) + \cdots + c_k f(v_k).$$

В частности, $f(0) = 0$: ведь $f(0) = f(0 \cdot v) = 0 \cdot f(v)$. Картинка — вектор яркостей пикселей: сделаем её вдвое ярче — выход линейного слоя удвоится, наложим две картинки — выходы сложатся.

Ловушка. «Линейная функция» из школы, $y = kx + b$, в этом смысле линейна только при $b = 0$: она переводит ноль в b. Нейрон со смещением, $y = 2x_1 - 3x_2 + 1$, тоже не линеен. Такие преобразования называют *аффинными*: линейное плюс постоянный вектор.

Нелинейна и активация $\mathrm{ReLU}(t) = \max(0, t)$: $\mathrm{ReLU}(1) + \mathrm{ReLU}(-1) = 1$, а $\mathrm{ReLU}(1 + (-1)) = 0$. Как раз активации и делают сеть нелинейной; без них, как покажет раздел 3, вся сеть — одно линейное преобразование.

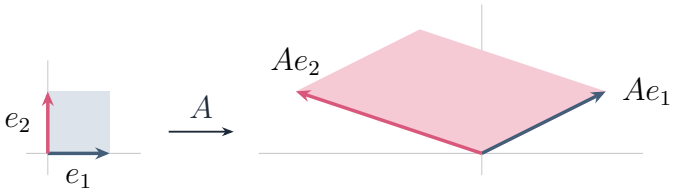
2 Матрица преобразования

Векторы $e_1 = (1, 0)$ и $e_2 = (0, 1)$ — *базисные*: любой вектор плоскости — их комбинация, $x = (x_1, x_2) = x_1 e_1 + x_2 e_2$. По линейности

$$f(x) = x_1 f(e_1) + x_2 f(e_2).$$

Значит, линейное преобразование целиком задано тем, куда оно переводит базисные векторы. Эти образы записывают столбцами в таблицу — это и есть *матрица* преобразования. У слоя из раздела 1 образ e_1, отзыва из одной похвалы, — это $(2, 1)$, а образ e_2 — $(-3, 1)$:

$$A = \begin{pmatrix} 2 & -3 \\ 1 & 1 \end{pmatrix}.$$



Правило. Столбец j матрицы — образ базисного вектора e_j.

Произведение матрицы на вектор Ax — это и есть $f(x)$, и считать его можно двумя способами. По столбцам: Ax — комбинация столбцов с коэффициентами из x,

$$\begin{pmatrix} 2 & -3 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 1 \end{pmatrix} = 3 \begin{pmatrix} 2 \\ 1 \end{pmatrix} + 1 \begin{pmatrix} -3 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \end{pmatrix}.$$

По строкам: координата i вектора Ax — скалярное произведение строки i на x: $2 \cdot 3 - 3 \cdot 1 = 3$ и $1 \cdot 3 + 1 \cdot 1 = 4$. Первый взгляд отвечает на вопрос «что делает преобразование», второй — «как считает каждый нейрон»: строка матрицы — веса одного выходного нейрона.

В общем случае вход длины n, выход длины m, и матрица A имеет размер $m \times n$: m строк, n столбцов. Элемент a_{ij} стоит в строке i и столбце j — это вес входа j в выходе i:

$$(Ax)_i = a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n.$$

И наоборот, любая таблица $m \times n$ задаёт этой формулой линейное преобразование. Так что линейные преобразования и матрицы — одно и то же, записанное по-разному.

Ловушка. Матрица $m \times n$ переводит векторы длины n в векторы длины m: столбцов в ней столько, сколько входов, а строк — сколько выходов. Слой из трёх признаков в два — матрица 2×3, а не 3×2.

Пример (эмбеддинги). В словаре четыре слова, у каждого — вектор длины 2, его эмбеддинг. Запишем эмбеддинги столбцами в матрицу 2×4:

$$W = \begin{pmatrix} 1 & 0 & 2 & -1 \\ 0 & 1 & 1 & 3 \end{pmatrix}.$$

Слово номер 3 — вектор $e_3 = (0, 0, 1, 0)$, и $We_3 = (2, 1)$ — третий столбец, эмбеддинг этого слова: так и устроен слой

эмбеддингов. Текст, где слово 1 встретилось дважды и слово 3 один раз, — вектор счётчиков $x = (2, 0, 1, 0)$, и $Wx = 2 \cdot (1, 0) + (2, 1) = (4, 1)$ — сумма эмбеддингов его слов.

Преобразование, которое ничего не меняет, переводит e_j в e_j; его матрица — *единичная* E: единицы на *диагонали* (элементы $a_{11}, a_{22}, \dots$), остальное нули. *Нулевая* матрица O переводит всё в ноль. Матрицы одного размера складывают поэлементно и поэлементно умножают на число — это матрицы преобразований $x \mapsto Ax + Bx$ и $x \mapsto c\,Ax$. Пример из нейросетей — остаточная связь: слой выдаёт вход плюс поправку, $x + Ax = (E + A)x$.

Галерея

Матрицу каждого из этих преобразований находим одним способом: смотрим, куда уходят e_1 и e_2.

Растяжение. Матрица $\operatorname{diag}(a, b) = \left(\begin{smallmatrix} a & 0 \\ 0 & b \end{smallmatrix}\right)$ переводит (x_1, x_2) в (ax_1, bx_2): каждая координата растягивается в своё число раз. Так меняют единицы признаков: граммы в килограммы — $a = 0{,}001$.

Поворот. Поворот на угол φ против часовой стрелки сохраняет параллелограммы и растяжения, поэтому линеен. Он переводит e_1 в $(\cos\varphi, \sin\varphi)$, а e_2 — в $(-\sin\varphi, \cos\varphi)$:

$$R_\varphi = \begin{pmatrix} \cos\varphi & -\sin\varphi \\ \sin\varphi & \cos\varphi \end{pmatrix}, \qquad R_{90^\circ} = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

Поворот картинки — обычная аугментация.

Проекция. Пусть ℓ — прямая через начало координат, u — вектор длины 1 вдоль неё. Проекция x на ℓ — вектор $p = (x \cdot u)\,u$: длина тени со знаком, умноженная на направление. Она линейна, потому что линейно скалярное произведение. При $u = (\cos\alpha, \sin\alpha)$ образы e_1 и e_2 — это $\cos\alpha \cdot u$ и $\sin\alpha \cdot u$:

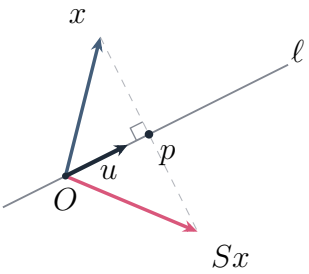
$$P = \begin{pmatrix} \cos^2\alpha & \cos\alpha\sin\alpha \\ \cos\alpha\sin\alpha & \sin^2\alpha \end{pmatrix}.$$

Проекция на направление — одно число вместо вектора; на этом стоит метод главных компонент.

Отражение. Разложим x на часть вдоль ℓ и часть поперёк: $x = p + (x - p)$. Отражение от ℓ первую оставляет, а у второй меняет знак:

$$Sx = p - (x - p) = 2p - x, \qquad S = 2P - E = \begin{pmatrix} \cos 2\alpha & \sin 2\alpha \\ \sin 2\alpha & -\cos 2\alpha \end{pmatrix}.$$

Удвоенные углы пришли из формул $2\cos^2\alpha - 1 = \cos 2\alpha$ и $2\sin\alpha\cos\alpha = \sin 2\alpha$.



Пример (прямая $y = 2x$). Направление $(1, 2)$, его длина $\sqrt{5}$, поэтому $\cos\alpha = 1/\sqrt{5}$, $\sin\alpha = 2/\sqrt{5}$, и

$$P = \frac{1}{5}\begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}, \qquad S = \frac{1}{5}\begin{pmatrix} -3 & 4 \\ 4 & 3 \end{pmatrix}.$$

Проверка: точка прямой остаётся на месте, $S(1, 2) = (1, 2)$, а перпендикуляр к прямой меняет знак, $S(2, -1) = (-2, 1)$.

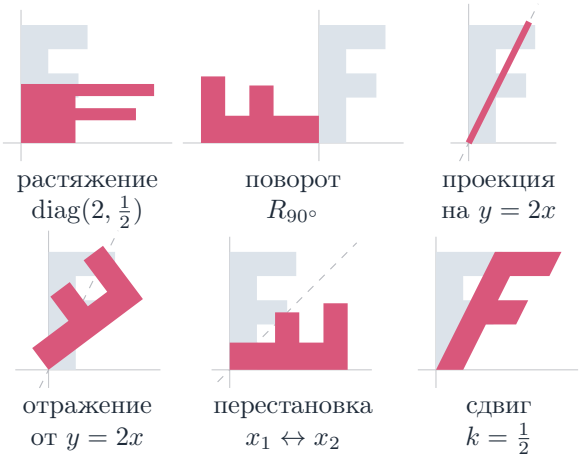
Перестановка координат. Матрица, у которой в каждой строке и в каждом столбце одна единица, а остальное нули, переставляет координаты:

$$\begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} x_3 \\ x_1 \\ x_2 \end{pmatrix}.$$

Единица в строке i и столбце j значит: на место i встаёт координата j. Для таблицы данных это перестановка

столбцов-признаков. На плоскости перестановка $(x_1, x_2) \mapsto (x_2, x_1)$ — отражение от прямой $y = x$.

Сдвиг. Матрица $\left(\begin{smallmatrix} 1 & k \\ 0 & 1 \end{smallmatrix}\right)$ переводит (x_1, x_2) в $(x_1 + kx_2,\ x_2)$: горизонтальные прямые скользят вдоль себя, тем дальше, чем выше. Это не параллельный перенос: перенос не линеен, он сдвигает ноль.



Пример (чёрный ящик). Слой спрятан, но его можно спросить: на вход $(1, 2)$ он ответил $(4, 1)$, на вход $(1, 3)$ — $(5, 3)$. Найдём его матрицу. Соберём e_1 и e_2 из известных входов: $e_2 = (1, 3) - (1, 2)$, $e_1 = 3 \cdot (1, 2) - 2 \cdot (1, 3)$. По линейности $Ae_2 = (5, 3) - (4, 1) = (1, 2)$ и $Ae_1 = 3 \cdot (4, 1) - 2 \cdot (5, 3) = (2, -3)$, так что $A = \left(\begin{smallmatrix} 2 & 1 \\ -3 & 2 \end{smallmatrix}\right)$. Не всякие два входа так годятся: если второй кратен первому, ответ на него ничего нового не скажет. Когда ответов хватает и как собрать матрицу сразу, — в разделе 8.

3 Композиция — произведение

Два слоя подряд: сначала B, потом A. Вектор x превращается в Bx, а тот — в $A(Bx)$. Композиция линейных

преобразований линейна, значит, у неё есть своя матрица. Её и называют *произведением* AB:

$$(AB)x = A(Bx).$$

Столбец j матрицы AB — образ e_j, то есть $A(Be_j)$, а Be_j — столбец j матрицы B. Значит, *столбец j произведения — это A, умноженная на столбец j матрицы B*. По элементам: строка i матрицы A скалярно на столбец j матрицы B,

$$(AB)_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{ik}b_{kj}.$$

Размеры: если B — матрица $k \times n$ (из $\mathbb{R}^n$ в $\mathbb{R}^k$), а A — матрица $m \times k$ (из $\mathbb{R}^k$ в $\mathbb{R}^m$), то AB — матрица $m \times n$. Внутренние размеры совпадают, внешние остаются.

> **Правило.** В записи ABx преобразования применяются справа налево: первым — то, что ближе к x. Последний применённый слой — левый множитель.

Пример (сеть без активаций). Два признака, скрытый слой из трёх нейронов, один выход:

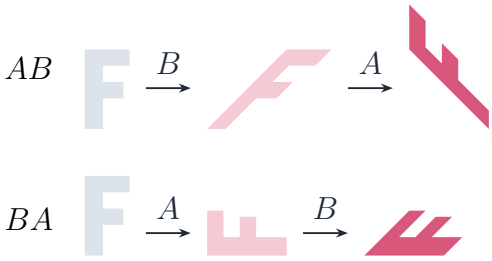
$$B = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 2 \end{pmatrix}, \qquad A = \begin{pmatrix} 3 & -1 & 2 \end{pmatrix}, \qquad AB = \begin{pmatrix} 2 & 3 \end{pmatrix}.$$

Вся сеть считает $2x_1 + 3x_2$ — это один нейрон. Сколько бы линейных слоёв ни стояло подряд, их произведение — одна матрица: глубина без активаций ничего не даёт.

Пример (порядок). Сдвиг $B = \left(\begin{smallmatrix} 1 & 1 \\ 0 & 1 \end{smallmatrix}\right)$ и поворот $A = R_{90^\circ}$:

$$AB = \begin{pmatrix} 0 & -1 \\ 1 & 1 \end{pmatrix}, \qquad BA = \begin{pmatrix} 1 & -1 \\ 1 & 0 \end{pmatrix}.$$

AB — сначала сдвиг, потом поворот, BA — наоборот, и выходит разное:



Ловушка. $AB \neq BA$, как правило. Бывает, что одно из произведений и вовсе не определено: в сети выше BA нет — у B два столбца, у A одна строка. Поэтому $(AB)^2 = ABAB$, а не A^2B^2, и $(A+B)^2 = A^2 + AB + BA + B^2$.

Зато скобки можно ставить как угодно: $(AB)C = A(BC)$.

Почему так. Обе части — матрица одного и того же преобразования «C, потом B, потом A»: $\big((AB)C\big)x = (AB)(Cx) = A\big(B(Cx)\big)$ и $\big(A(BC)\big)x = A\big((BC)x\big) = A\big(B(Cx)\big)$. Так же проверяется раскрытие скобок: $A(B+C) = AB + AC$ и $(A+B)C = AC + BC$.

Как устроено. Результат от скобок не зависит, а работа — зависит: для матриц $n \times n$ счёт $A(Bx)$ стоит $2n^2$ умножений, а $(AB)x$ — $n^3 + n^2$. Поэтому нейросеть считают слой за слоем.

Транспонированная матрица $A^\top$ — та же таблица, где строки стали столбцами: $(A^\top)_{ij} = a_{ji}$. Столбец x после транспонирования — строка $x^\top$, и скалярное произведение — строка на столбец: $x \cdot y = x^\top y$.

Утверждение. $(AB)^\top = B^\top A^\top$ — порядок множителей меняется.

Почему так. Элемент (i, j) слева — элемент (j, i) матрицы AB, то есть $\sum_t a_{jt} b_{ti}$. Справа — строка i матрицы $B^\top$ на столбец j матрицы $A^\top$: $\sum_t b_{ti} a_{jt}$. Это одна и та же сумма.

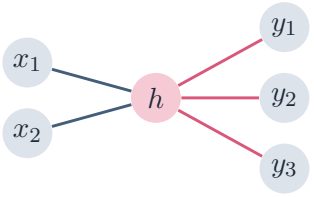
Пример (таблица данных). В ML объекты — строки таблицы X: строка i — это $x_i^\top$, вектор признаков объекта i, записанный строкой. Слой с матрицей A переводит x_i в Ax_i, а в строчной записи $(Ax_i)^\top = x_i^\top A^\top$. Значит, всю таблицу слой переводит в $XA^\top$ — все объекты одним умножением. Поэтому в библиотеках слой записан как $XW^\top$, с транспонированной матрицей весов.

4 Столбец на строку

Вектор — матрица в один столбец, $n \times 1$, а $v^\top$ — в одну строку, $1 \times n$. Их можно умножать по общему правилу, и порядок снова важен. Строка на столбец — число: $v^\top u = v_1u_1 + \cdots + v_nu_n$. Столбец на строку — матрица $uv^\top$ с элементами u_iv_j, таблица всех попарных произведений; длины u и v здесь могут быть разными.

Что делает $uv^\top$, видно из ассоциативности: $(uv^\top)x = u(v^\top x) = (v \cdot x)\,u$. Преобразование меряет одно число — скалярное произведение с v — и выдаёт вектор u, умноженный на это число. Все выходы кратны u и лежат на одной прямой.

Пример (узкое горлышко). Между входом из двух признаков и выходом из трёх стоит один нейрон: он считает $h = 3x_1 + x_2$, а выход — $h \cdot (1, 2, -1)$. Матрица сети — произведение слоёв:



$$\begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix} \begin{pmatrix} 3 & 1 \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 6 & 2 \\ -3 & -1 \end{pmatrix}$$

Строки этой матрицы пропорциональны друг другу, и столбцы тоже — признак ранга 1, о ранге — раздел 9.

Проекция на прямую из раздела 2 устроена так же: $Px = (x \cdot u)\,u = u(u^\top x)$, то есть $P = uu^\top$.

Утверждение. Для векторов u и v одной длины $(uv^\top)^k = (v^\top u)^{k-1}\,uv^\top$.

Почему так. Переставим скобки: $(uv^\top)(uv^\top) = u\,(v^\top u)\,v^\top$, а $v^\top u$ — число, его можно вынести вперёд. Каждый следующий множитель добавляет ещё одно такое число.

Пример. Пусть $u = (1, 2)$. С $v = (1, 1)$ выходит $v^\top u = 3$, так что у $M = uv^\top = \left(\begin{smallmatrix} \frac{1}{2} & \frac{1}{2} \\ \cdot & \cdot \end{smallmatrix}\right)$ степени $M^k = 3^{k-1}M$. С $v = (3, -1)$: $v^\top u = 1$, и $M^2 = M$ — повторное применение ничего не меняет, как у проекции. С $v = (2, -1)$: $v^\top u = 0$, и $M^2 = O$ — ненулевая матрица с нулевым квадратом.

Утверждение. Если A — матрица $n \times m$, а B — матрица $m \times n$, то $(AB)^k = A\,(BA)^{k-1}B$.

Почему так. В произведении $ABAB\cdots AB$ поставим скобки иначе: $A(BA)(BA)\cdots(BA)B$. Пар BA ровно $k - 1$.

Польза — когда m много меньше n. Тогда AB — большая матрица $n \times n$, а BA — маленькая, $m \times m$, и степени считают у неё: при $n = 1000$ и $m = 2$ вместо матриц 1000×1000 перемножают 2×2. Формула для $uv^\top$ — случай $m = 1$: там $BA = v^\top u$, просто число.

5 Степени

A^k — преобразование A, применённое k раз подряд, $A^0 = E$. По ассоциативности $A^k A^l = A^{k+l}$. Считать степени в лоб долго, поэтому в задачах ищут, как матрица устроена.

Пример (поворот). Поворот на α, потом на β — поворот на $\alpha + \beta$: $R_\beta R_\alpha = R_{\alpha+\beta}$, и $R_\varphi^k = R_{k\varphi}$. Перемножьте матрицы и сравните первые столбцы — выйдут формулы косинуса и синуса суммы. Поворот на 120°, применённый трижды, —

поворот на $360°$: $R_{120°}^3 = E$, хотя сама матрица $R_{120°} = \frac{1}{2}\begin{pmatrix} -1 & -\sqrt{3} \\ \sqrt{3} & -1 \end{pmatrix}$ на E ничуть не похожа.

Пример (перестановка). Матрица P из галереи сдвигает координаты по кругу: $(x_1, x_2, x_3) \mapsto (x_3, x_1, x_2)$. Три таких сдвига возвращают всё на место, $P^3 = E$, и дальше степени повторяются: $P^{100} = (P^3)^{33}P = P$. Любая перестановка распадается на циклы, и $P^k = E$ ровно тогда, когда k делится на длину каждого цикла; наименьшее такое k, *период*, — НОК длин циклов. С циклами длины 3 и 4 период равен 12.

Матрица N *нильпотентна*, если $N^k = O$ при каком-то k.

Пример (лаг). Ряд наблюдений (x_1, x_2, x_3) по дням. Признак «значение вчера» — сдвиг ряда на шаг:

$$S = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}, \qquad S\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ x_1 \\ x_2 \end{pmatrix}, \qquad S^2\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ x_1 \end{pmatrix},$$

и $S^3 = O$: за три сдвига ряд уходит целиком. Ещё пример — $uv^\top$ при $v^\top u = 0$ из раздела 4.

Утверждение. Если $AB = BA$, то

$$(A + B)^k = \sum_{j=0}^{k} \binom{k}{j} A^{k-j} B^j.$$

Почему так. Раскроем скобки в $(A + B)(A + B) \cdots (A + B)$: выйдет сумма всех слов длины k из букв A и B. Если $AB = BA$, в каждом слове все A можно собрать вперёд, и слово с j буквами B станет $A^{k-j}B^j$. Таких слов $\binom{k}{j}$.

Главный случай — $E + N$ с нильпотентной N. Единичная матрица перестановочна с любой, а степени N быстро кончаются. Если $N^3 = O$, то

$$(E + N)^k = E + kN + \binom{k}{2} N^2.$$

Пример (снова лаг). Матрица $E + S$ делает из ряда ряд «сегодня плюс вчера». Десять таких шагов —

$$(E+S)^{10} = E + 10S + 45S^2 = \begin{pmatrix} 1 & 0 & 0 \\ 10 & 1 & 0 \\ 45 & 10 & 1 \end{pmatrix}.$$

Пример. С числом вместо единицы — так же: λE перестановочна со всем. При $N = \left(\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right)$, $N^2 = O$, и $\left(\begin{smallmatrix} 2 & 1 \\ 0 & 2 \end{smallmatrix}\right)^k = (2E+N)^k = 2^k E + k\,2^{k-1} N = \left(\begin{smallmatrix} 2^k & k\,2^{k-1} \\ 0 & 2^k \end{smallmatrix}\right)$.

Ловушка. Бином Ньютона верен только для перестановочных слагаемых. «Диагональная плюс нильпотентная» — ещё не повод: при $D = \operatorname{diag}(1, 2)$ и той же N выходит $DN = N$, а $ND = 2N$, и

$$(D+N)^2 = \begin{pmatrix} 1 & 3 \\ 0 & 4 \end{pmatrix} \neq D^2 + 2DN + N^2 = \begin{pmatrix} 1 & 2 \\ 0 & 4 \end{pmatrix}.$$

Прежде чем раскрывать скобки по биному, надо проверить, что $AB = BA$.

Пример (числа Фибоначчи). $f_0 = 0$, $f_1 = 1$, $f_{n+1} = f_n + f_{n-1}$. Следующий член зависит от двух последних, поэтому состояние — пара $s_n = (f_{n+1}, f_n)$, и шаг — линейное преобразование:

$$\begin{pmatrix} f_{n+1} \\ f_n \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} f_n \\ f_{n-1} \end{pmatrix}, \qquad s_n = F s_{n-1} = F^n s_0.$$

Так устроена и рекуррентная сеть без активации: состояние после t шагов — $W^t h_0$. Здесь $s_0 = (1, 0) = e_1$, поэтому первый столбец F^n — это $F^n e_1 = s_n$, а второй — $F^{n-1}(Fe_2) = F^{n-1}e_1 = s_{n-1}$, то есть $F^n = \left(\begin{smallmatrix} f_{n+1} & f_n \\ f_n & f_{n-1} \end{smallmatrix}\right)$. Сама матрица подчиняется той же рекурренте: $F^2 = \left(\begin{smallmatrix} 2 & 1 \\ 1 & 1 \end{smallmatrix}\right) = F + E$. Умножив на F^k, получим $F^{k+2} = F^{k+1} + F^k$ — для всех элементов сразу.

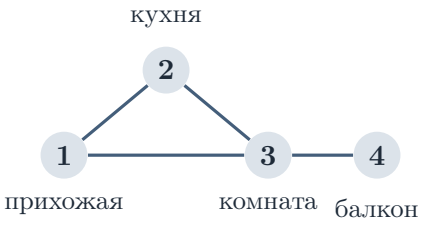
Правило. Если матрица шага подчиняется рекурренте, то ей подчиняется и любая линейная величина от её степеней: элемент, сумма элементов, след.

Например, сумма диагонали F^k: при $k = 0$ это 2 (у E), при $k = 1$ это 1, дальше каждый член — сумма двух предыдущих: $3, 4, 7, 11, 18, \ldots$ Это числа Люка, и считать для них F^k не нужно.

Как устроено. Степень считают возведением в квадрат: $F^{2k} = (F^k)^2$, $F^{2k+1} = F^{2k}F$. Это не больше $2\log_2 n$ умножений матриц 2×2: миллионное число Фибоначчи — примерно за сорок.

6 Маршруты в графе

Робот-пылесос ездит по квартире из четырёх комнат и за шаг переезжает в соседнюю. Комнаты — вершины графа, двери — рёбра. *Матрица смежности*: $a_{ij} = 1$, если из i в j можно попасть за шаг, иначе 0.



$$A = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

Двери пропускают в обе стороны, поэтому A симметрична: $A^\top = A$; при проезде в одну сторону она была бы несимметричной, а остальное не изменилось бы. Граф состояний в ML устроен так же: вершины — состояния агента или токены, рёбра — разрешённые переходы.

Утверждение. $(A^k)_{ij}$ — число маршрутов длины k из i в j, то есть последовательностей вершин $i = v_0, v_1, \ldots, v_k = j$, где каждые две соседние соединены ребром.

Почему так. Индукция по k; при $k = 1$ это определение A. Маршрут длины $k+1$ из i в j — маршрут длины k из i в какую-то вершину t и шаг из t в j. Таких маршрутов $\sum_t (A^k)_{it}\, a_{tj}$, а это и есть элемент (i,j) произведения $A^k A = A^{k+1}$.

Пример. Две степени:

$$A^2 = \begin{pmatrix} 2 & 1 & 1 & 1 \\ 1 & 2 & 1 & 1 \\ 1 & 1 & 3 & 0 \\ 1 & 1 & 0 & 1 \end{pmatrix}, \qquad A^3 = \begin{pmatrix} 2 & 3 & 4 & 1 \\ 3 & 2 & 4 & 1 \\ 4 & 4 & 2 & 3 \\ 1 & 1 & 3 & 0 \end{pmatrix}.$$

С балкона в комнату за три шага — $(A^3)_{43} = 3$ маршрута: 4–3–1–3, 4–3–2–3, 4–3–4–3. На диагонали A^2 — число соседей: маршрут длины 2 из i в i — туда и обратно. Сумма строки i матрицы A^k — все маршруты длины k из i.

Петля — ребро из вершины в неё же: робот может остаться на месте. С петлями у всех вершин матрица — $A + E$, и $(A+E)^k$ считает маршруты, где на каждом шаге можно стоять. E перестановочна с A, поэтому работает бином:

$$(A+E)^k = \sum_{j=0}^{k} \binom{k}{j} A^j.$$

Смысл формулы прямой: выбрать, на каких j шагах из k робот едет, и проехать по маршруту длины j. С балкона на кухню за три шага с остановками — $\binom{3}{2}(A^2)_{42} + \binom{3}{3}(A^3)_{42} = 3 + 1 = 4$ маршрута, без остановок — один.

7 След

След квадратной матрицы — сумма элементов диагонали: $\operatorname{tr} A = a_{11} + a_{22} + \cdots + a_{nn}$. Он линеен: $\operatorname{tr}(A+B) = \operatorname{tr} A + \operatorname{tr} B$, $\operatorname{tr}(cA) = c \operatorname{tr} A$. При транспонировании диагональ не меняется, поэтому $\operatorname{tr} A^\top = \operatorname{tr} A$.

Утверждение. $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ для A размера $m \times n$ и B размера $n \times m$. Матрицы AB и BA при этом могут быть даже разного размера.

Почему так. $\operatorname{tr}(AB) = \sum_i \sum_t a_{it} b_{ti}$, а $\operatorname{tr}(BA) = \sum_t \sum_i b_{ti} a_{it}$. Это сумма одних и тех же произведений $a_{it} b_{ti}$ по всем парам (i, t), только в другом порядке.

Пример. $\operatorname{tr}(uv^\top) = \operatorname{tr}(v^\top u) = v^\top u$: след матрицы ранга 1 — скалярное произведение. У $M = \left(\begin{smallmatrix} \frac{1}{2} & \frac{1}{2} \end{smallmatrix}\right)$ из раздела 4 след $1 + 2 = 3 = v^\top u$.

Пример. Сумма квадратов всех элементов — тоже след: $\operatorname{tr}(A^\top A) = \sum_{i,j} a_{ij}^2$, потому что элемент j диагонали $A^\top A$ — столбец j скалярно на себя. В ML так записывают штраф за большие веса и сумму квадратов ошибок.

Для трёх множителей $\operatorname{tr}(ABC) = \operatorname{tr}(BCA) = \operatorname{tr}(CAB)$: правило применяется к A и BC, потом к AB и C. Множители можно сдвигать по кругу, но не переставлять как угодно.

Ловушка. $\operatorname{tr}(ABC)$ и $\operatorname{tr}(ACB)$ бывают разными. Возьмём матрицы с одной единицей:

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad C = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix}.$$

Тогда $ABC = A$ и $\operatorname{tr}(ABC) = 1$, а $ACB = O$ и $\operatorname{tr}(ACB) = 0$.

Пример (замкнутые маршруты). Диагональ A^k — маршруты, которые возвращаются, откуда начались, а $\operatorname{tr} A^k$ — все замкнутые маршруты длины k. В графе комнат $\operatorname{tr} A^3 = 6$: это единственный треугольник прихожая–кухня–комната, обойдённый из каждой его вершины в двух направлениях. В графе без петель $\operatorname{tr} A^3$ всегда равен шестикратному числу треугольников, а $\operatorname{tr} A^2$ — удвоенному числу рёбер: у нас $\operatorname{tr} A^2 = 8$, рёбер четыре.

8 Обратимость

Слой переводит x в $y = Ax$. Можно ли по выходу восстановить вход? Нельзя, если два разных входа дают один выход: $Ax = Ax'$. Это то же, что $A(x - x') = 0$, поэтому всё решает множество векторов, которые слой переводит в ноль, — *ядро* $\ker A = \{x : Ax = 0\}$. Ноль в ядре есть всегда. Если там есть что-то ещё, слой теряет информацию: входы x и $x + z$ при $z \in \ker A$ для него неразличимы.

Пример. Слой $\left(\begin{smallmatrix} 1 & 2 \\ 2 & 4 \end{smallmatrix}\right)$ видит вход только через $x_1 + 2x_2$: оба выхода — её кратные. Ядро — прямая $x_1 + 2x_2 = 0$, векторы, кратные $(2, -1)$. Отзывы $(3, 1)$ и $(5, 0)$ слой не различит. У проекции на прямую ядро — перпендикулярная прямая, у поворота — один ноль.

Векторы $v_1, \ldots, v_k$ *линейно независимы*, если их комбинация $c_1 v_1 + \cdots + c_k v_k$ равна нулю только при всех $c_i = 0$; иначе один из них выражается через остальные. Вектор Ac — комбинация столбцов A с коэффициентами из c, поэтому $\ker A = \{0\}$ ровно тогда, когда столбцы A линейно независимы. *Базис* $\mathbb{R}^n$ — набор векторов, через который любой вектор выражается, и притом единственным образом; $e_1, \ldots, e_n$ — базис. Примем без доказательства: в $\mathbb{R}^n$ любые n независимых векторов — базис, а больше n векторов всегда зависимы.

Матрица A^{-1} *обратна* к квадратной матрице A, если $A^{-1}A = AA^{-1} = E$: она отменяет преобразование. Матрицу, у которой обратная есть, называют *обратимой*.

Утверждение. Квадратная матрица обратима тогда и только тогда, когда её ядро — только ноль.

Почему так. Если обратная есть и $Ax = 0$, то $x = A^{-1}Ax = 0$. Обратно, пусть ядро нулевое. Тогда столбцы A — n независимых векторов в $\mathbb{R}^n$, то есть базис, и каждый y единственным образом равен Ax. Преобразование $y \mapsto x$

определено и линейно: если $Ax = y$ и $Ax' = y'$, то $A(x + x') = y + y'$ и $A(cx) = cy$. Его матрица и есть A^{-1}.

Утверждение (2×2). Матрица $A = \left(\begin{smallmatrix} a & b \\ c & d \end{smallmatrix}\right)$ обратима тогда и только тогда, когда $ad - bc \neq 0$, и тогда

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

Почему так. Перемножим: $\left(\begin{smallmatrix} a & b \\ c & d \end{smallmatrix}\right) \left(\begin{smallmatrix} d & -b \\ -c & a \end{smallmatrix}\right) = (ad - bc)E$, и в другом порядке тоже. Если $ad - bc \neq 0$, делим на него. Если же $ad - bc = 0$, это равенство говорит, что A переводит в ноль оба столбца $(d, -c)$ и $(-b, a)$. При $A \neq O$ хоть один из них не ноль, и ядро не нулевое.

Число $ad - bc$ — *определитель* $\det A$. Его смысл: во сколько раз преобразование меняет площади; знак минус — если оно меняет ориентацию, как отражение. У слоя из раздела 2 $\det A = 2 \cdot 1 - (-3) \cdot 1 = 5$, и единичный квадрат перешёл в параллелограмм площади 5. Определители больших матриц — в следующем уроке.

Пример. Для этого слоя $A^{-1} = \frac{1}{5}\left(\begin{smallmatrix} 1 & 3 \\ -1 & 2 \end{smallmatrix}\right)$, и выход $(3, 4)$ переходит обратно в $\frac{1}{5}(1 \cdot 3 + 3 \cdot 4,\ -1 \cdot 3 + 2 \cdot 4) = (3, 1)$ — тот самый отзыв.

Обратные к матрицам галереи видны без формулы: поворот на φ отменяется поворотом на $-\varphi$, отражение — им же, сдвиг на k — сдвигом на $-k$; у поворота и перестановки обратная равна транспонированной. И $(AB)^{-1} = B^{-1}A^{-1}$: чтобы отменить «B, потом A», сначала отменяют A.

Пример (матрица по ответам). Вернёмся к чёрному ящику из раздела 2. Пусть на входы $x_1, \ldots, x_n$ слой ответил $y_1, \ldots, y_n$. Запишем входы столбцами в матрицу X, ответы — в Y. Тогда $AX = Y$: столбец j слева — это Ax_j. Если входы —

базис, X обратима, и $A = YX^{-1}$. Для запросов $(1,2)$ и $(1,3)$ с ответами $(4,1)$ и $(5,3)$ матрица $X = \left(\begin{smallmatrix} 1 & 1 \\ 2 & 3 \end{smallmatrix}\right)$, $X^{-1} = \left(\begin{smallmatrix} 3 & -1 \\ -2 & 1 \end{smallmatrix}\right)$, и

$$A = YX^{-1} = \begin{pmatrix} 4 & 5 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 3 & -1 \\ -2 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ -3 & 2 \end{pmatrix}$$

— та же матрица, что в разделе 2. Если запросы зависимы, матрица по ним не восстанавливается: о направлениях, которых нет среди их комбинаций, ответы ничего не говорят.

> **Правило.** Для квадратной матрицы A равносильно: A обратима; ядро — только ноль; столбцы независимы; столбцы — базис. Для 2×2 к этому списку добавляется $ad - bc \neq 0$.

9 Ранг

Образ $\operatorname{Im} A$ — все векторы вида Ax, то есть все комбинации столбцов A. Сумма и кратное векторов образа тоже лежат в образе: это *подпространство*. Его базис — независимые векторы в нём, через которые выражаются все остальные; число векторов во всех базисах одно и то же, это *размерность*. *Ранг* $\operatorname{rank} A$ — размерность образа, то есть наибольшее число независимых столбцов.

Пример. У поворота ранг 2, у проекции на прямую и у $uv^\top$ — 1, у нулевой матрицы — 0. И ещё

$$\operatorname{rank} \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 0 & 1 \end{pmatrix} = 2 :$$

первые два столбца не пропорциональны, а третий — их сумма.

Утверждение. $\dim \ker A + \operatorname{rank} A = n$, числу столбцов. Сколько измерений входа слой теряет, столько не хватает образу. Это примем без доказательства.

Пусть $\operatorname{rank} A = r$ и $c_1, \ldots, c_r$ — базис образа. Каждый столбец A — комбинация $c_1, \ldots, c_r$. Запишем $c_1, \ldots, c_r$ столбцами в матрицу C размера $m \times r$, а коэффициенты комбинаций — столбцами в матрицу R размера $r \times n$. Тогда $A = CR$. Это *скелетное разложение* — то же узкое горлышко, только шириной r.

Утверждение. Независимых строк столько же, сколько независимых столбцов.

Почему так. Строка i матрицы CR — строка i матрицы C, умноженная на R, то есть комбинация r строк R. Значит, независимых строк у A не больше r. То же для $A^\top$ даёт обратное неравенство.

Утверждение. Матрица ранга r — сумма r матриц вида $uv^\top$; ранг 1 — ровно у матриц $uv^\top$ с ненулевыми u и v.

Почему так. Элемент (i, j) матрицы CR — сумма r слагаемых $c_{ik} r_{kj}$, и слагаемое номер k — элемент $c_k \rho_k^\top$, где $\rho_k^\top$ — строка k матрицы R. Обратно, у $uv^\top$ столбец j равен $v_j u$: все столбцы кратны u.

Утверждение. $\operatorname{rank}(AB) \le \min(\operatorname{rank} A, \operatorname{rank} B)$.

Почему так. Образ AB — это A, применённая к образу B, и он лежит внутри образа A: $\operatorname{rank}(AB) \le \operatorname{rank} A$. С другой стороны, образ B — комбинации $\operatorname{rank} B$ базисных векторов, а его образ под A — комбинации их образов. Их столько же, поэтому $\operatorname{rank}(AB) \le \operatorname{rank} B$.

Поэтому сеть без активаций с узким слоем ширины k — матрица ранга не больше k, как ни широки остальные слои.

Утверждение. $\operatorname{rank}(A + B) \le \operatorname{rank} A + \operatorname{rank} B$.

Почему так. Столбцы $A + B$ — суммы столбцов A и B, поэтому лежат среди комбинаций базиса образа A и базиса образа B вместе. А там $\operatorname{rank} A + \operatorname{rank} B$ векторов.

Утверждение. Если $a_{ij} = f_1(x_i) g_1(x_j) + \cdots + f_m(x_i) g_m(x_j)$, то ранг такой матрицы не больше m.

Почему так. Слагаемое $f_k(x_i)g_k(x_j)$ как таблица по i и j — это $u_k v_k^\top$ с $u_k = (f_k(x_1), f_k(x_2), \dots)$ и $v_k = (g_k(x_1), g_k(x_2), \dots)$, ранга не больше 1. Ранг суммы m таких — не больше m.

Пример. Таблица умножения $a_{ij} = ij$ — ранг 1. Матрица $a_{ij} = i + j$ — это $i \cdot 1 + 1 \cdot j$, ранг не больше 2 при любом размере (и ровно 2, если размер не меньше двух). Матрица $a_{ij} = \sin(x_i + x_j) = \sin x_i \cos x_j + \cos x_i \sin x_j$ — тоже ранг не больше 2.

Пример (матрица Грама). Эмбеддинги n объектов длины d — строки таблицы X размера $n \times d$. Матрица сходств $G = XX^\top$ размера $n \times n$ состоит из скалярных произведений: $g_{ij} = x_i \cdot x_j$. Сколько бы ни было объектов, $\operatorname{rank} G \le \operatorname{rank} X \le d$. Три слова с эмбеддингами $(1, 0)$, $(1, 1)$, $(0, 2)$:

$$G = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 2 \\ 0 & 2 & 4 \end{pmatrix},$$

и строка 3 равна удвоенной разности строк 2 и 1: ранг 2.

Утверждение. $\operatorname{rank}(XX^\top) = \operatorname{rank} X$.

Почему так. Если $XX^\top v = 0$, то $0 = v^\top XX^\top v$ — сумма квадратов координат $X^\top v$, так что $X^\top v = 0$. Ядра $XX^\top$ и $X^\top$ совпадают, столбцов у них по n, и по формуле $\dim\ker + \operatorname{rank} = n$ выходит $\operatorname{rank}(XX^\top) = \operatorname{rank} X^\top = \operatorname{rank} X$.

10 Перестановочные матрицы

Матрицы A и B *перестановочны*, если $AB = BA$. Так бывает редко, но несколько случаев надо знать. E и вообще λE перестановочны с любой матрицей: $(\lambda E)A = \lambda A = A(\lambda E)$. A перестановочна со своими степенями и с любой суммой $c_0 E + c_1 A + c_2 A^2 + \dots$ Повороты плоскости перестановочны между собой: $R_\alpha R_\beta = R_{\alpha+\beta} = R_\beta R_\alpha$.

Утверждение. Если $D = \operatorname{diag}(d_1, \ldots, d_n)$ и все d_i различны, то с D перестановочны только диагональные матрицы.

Почему так. Умножение на D слева умножает строку i на d_i, справа — столбец j на d_j: $(DA)_{ij} = d_i a_{ij}$, $(AD)_{ij} = a_{ij} d_j$. Равенство $DA = AD$ значит $(d_i - d_j)a_{ij} = 0$ при всех i, j. При $i \neq j$ числа d_i и d_j разные, поэтому $a_{ij} = 0$.

Смысл: D растягивает признаки в разное число раз, и с ней перестановочно только то, что признаки не смешивает. Если некоторые d_i равны, смешивать можно признаки, растянутые одинаково: с $\operatorname{diag}(1, 1, 2)$ перестановочна любая матрица, где $a_{13} = a_{23} = a_{31} = a_{32} = 0$. Перестановочность нужна для бинома из раздела 5 и для $(AB)^k = A^k B^k$.

11 Итог: если в задаче матрица

Вопросы, которые стоит задать себе первыми:

- Куда она переводит базисные векторы? Часто это преобразование из галереи или их композиция.
- Не произведение ли она узких: $uv^\top$, CR, $XX^\top$? Тогда ранг мал, а степени и след считаются через BA и $v^\top u$.
- Степень — посчитать A^2, A^3 и найти закономерность: период, нильпотентность, $E + N$ с биномом, рекуррента для A.
- Нули и единицы — не граф ли это? Элементы степени — маршруты, след — замкнутые маршруты.
- След — сдвигать множители по кругу; $\operatorname{tr}(uv^\top) = v^\top u$.
- Обратима ли: ядро, независимость столбцов, $ad - bc$ для 2×2.
- Проверить ответ на маленьком случае или программой: numpy перемножает матрицы, `fractions` считает точными дробями.