



Линейные модели

Шпаргалка



§1 Модель

Обучение с учителем: n объектов, у каждого d признаков $x_i \in \mathbb{R}^d$ и известный ответ y_i . Ищем функцию $a(x)$, которая хорошо предсказывает ответ на новых объектах; «хорошо» задаёт функция потерь L .

Def (линейная модель). Каждый признак умножается на свой вес, и всё складывается:

$$a(x) = w_0 + w_1x_1 + \dots + w_dx_d.$$

Свободный член w_0 (bias) сдвигает ответ. Добавим признак $x_0 = 1$ — и w_0 станет обычным весом: $a(x) = \langle w, x \rangle$.

Матрица «объекты — признаки» X : строка — объект. Тогда Xw — прогнозы для всех n объектов, $e = Xw - y$ — вектор ошибок.


При $d = 1$ модель — прямая, при $d = 2$ — плоскость, дальше — гиперплоскость. Знак w_j говорит, растёт ли ответ с ростом j -го признака, модуль — насколько, при прочих равных. Сравнивать веса между собой можно только при одном масштабе признаков и без сильной корреляции.

Замечание (нелинейные признаки). Модель линейна по весам, а не по x . Добавим признаки x^2 , x^3 , $\log x$, $\sqrt{x}$, $\sin x$, произведения x_1x_2 , one-hot-кодирование категорий — и линейная модель опишет хоть параболу $y = x^2$.

Def (функции потерь). Для ошибки $e = a(x) - y$:

- MSE, e^2 — гладкая, решение есть формулой, но боится выбросов: большая ошибка входит в квадрате;
- MAE, $|e|$ — устойчива к выбросам;
- Хьюбер — квадрат у нуля и модуль на хвостах, гладкая и устойчивая:

$$L_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \leq \delta, \\ \delta(|e| - \frac{\delta}{2}), & |e| > \delta. \end{cases}$$



§2 Аналитическое решение

$$L(w) = \frac{1}{n} \|Xw - y\|^2 \rightarrow \min_w.$$

Утверждение (матричные производные). $\nabla_w \langle a, w \rangle = a$ и $\nabla_w (w^\top A w) = (A + A^\top) w$; для симметричной A , например $X^\top X$, это $2Aw$. Проверяются покомпонентно.

Норма через скалярное произведение; два средних слагаемых равны, потому что $(AB)^\top = B^\top A^\top$:

$$\|Xw - y\|^2 = w^\top X^\top X w - 2y^\top Xw + y^\top y.$$

Необходимое условие минимума:

$$\nabla_w L = \frac{2}{n} (X^\top X w - X^\top y) = 0.$$

$$X^\top X w = X^\top y$$

Это нормальное уравнение. Если $X^\top X$ обратима,

$$w^* = (X^\top X)^{-1} X^\top y.$$

Это минимум: гессиан $\frac{2}{n} X^\top X$ неотрицательно определён, $v^\top X^\top X v = \|Xv\|^2 \geq 0$. Функция выпукла, и точка, где градиент равен нулю, — глобальный минимум.

Утверждение (когда $X^T X$ обратима). Ровно тогда, когда столбцы X линейно независимы. Если $X^T X v = 0$, то $\|X v\|^2 = v^T X^T X v = 0$, то есть $X v = 0$.

Пример (дубль признака). Площадь в квадратных метрах и она же в квадратных футах — пропорциональные столбцы: $X^T X$ вырождена, решение не единственно. Почти пропорциональные столбцы (мультиколлинеарность) дают почти вырожденную матрицу и огромные неустойчивые веса.

Утверждение (геометрический смысл). Векторы $X w$ образуют подпространство — линейную оболочку столбцов X . Лучший прогноз $X w^*$ — проекция y на него: ошибка $y - X w^*$ перпендикулярна каждому столбцу, $X^T (y - X w^*) = 0$. Это и есть нормальное уравнение.

Пример (один признак). Для $a(x) = w x + b$

$$w = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \quad b = \bar{y} - w \bar{x}.$$

Точки $(1; 2)$, $(2; 3)$, $(3; 5)$, $(4; 6)$: $\bar{x} = 2,5$, $\bar{y} = 4$, числитель 7, знаменатель 5, так что $w = 1,4$ и $b = 0,5$.

Замечание (итоги). Плюсы:

- точный ответ за один шаг;
- никаких гиперпараметров — ни шага, ни числа итераций;
- гарантированно глобальный минимум.

Минусы:

- время $O(nd^2 + d^3)$ — медленно при больших d ;
- вся X должна поместиться в память;
- неустойчиво при мультиколлинеарности;
- только для MSE: для MAE и log-loss формулы нет.

При d до нескольких тысяч аналитика хороша; для больших данных и других потерь нужен итеративный метод.

§3 Градиентный спуск

Утверждение (почему антиградиент). Вблизи w функция почти линейна: $L(w + h) \approx L(w) + \langle \nabla L, h \rangle$. Среди шагов h одной длины $\langle \nabla L, h \rangle$ меньше всего у направленного против ∇L — по неравенству Коши — Буняковского. Антиградиент перпендикулярен линии уровня.

Def (алгоритм).

1. $w^{(0)} = 0$ или малые случайные числа.
2. Градиент $\nabla L(w^{(t)})$ по всей выборке.
3. Шаг $w^{(t+1)} = w^{(t)} - \eta \nabla L(w^{(t)})$.
4. Стоп, если $\|\nabla L\| < \varepsilon$, веса почти не меняются или кончился лимит итераций; иначе к шагу 2.

Утверждение (градиент MSE). По цепному правилу

$$\frac{\partial L}{\partial w_j} = \frac{2}{n} \sum_i (\langle w, x_i \rangle - y_i) x_{ij},$$

потому что $\partial \langle w, x_i \rangle / \partial w_j = x_{ij}$. Сумма $\sum_i e_i x_{ij}$ — это j -я координата $X^\top e$:

$$\nabla_w L = \frac{2}{n} X^\top (Xw - y)$$

Пример (две итерации). Модель $a(x) = wx$, точки $(1; 2)$, $(2; 4)$ и $(3; 6)$, шаг $\eta = 0,05$; истинное $w = 2$.

t	$w^{(t)}$	ошибки $wx_i - y_i$	∇L	L
0	0	-2; -4; -6	-18,67	18,67
1	0,933	-1,07; -2,13; -3,20	-9,96	5,31
2	1,431	-0,57; -1,14; -1,71	-5,31	1,51

Расстояние до ответа каждый шаг умножается на

$$1 - \eta \cdot \frac{2}{n} \sum_i x_i^2 = 1 - \frac{28}{3} \eta \approx 0,533 :$$

сходимость геометрическая. При $\eta > \frac{3}{14}$ множитель по модулю больше единицы, и спуск расходится.

Замечание (шаг η). Маленький — медленно, большой — колебания и расходимость. Смотреть на график ошибки по итерациям.

Замечание (масштабирование). Каждый признак заменяют на $(x_j - \mu_j)/\sigma_j$, где μ_j и σ_j — среднее и стандартное отклонение, посчитанные только по `train`. Для аналитики не обязательно, для спуска критично: при разных масштабах линии уровня вытянуты, и спуск идёт зигзагом, как на обложке.

Def (SGD и mini-batch). Полный градиент стоит $O(nd)$; при $n = 10^8$ это дорого. SGD берёт на шаг один случайный объект, mini-batch — b объектов, обычно от 32 до 512. Оценка градиента несмещённая, но шумная. В библиотеках mini-batch часто называют SGD.

- GD: вся выборка, шаг $O(nd)$; направление точное, стабильно, но медленно на больших n .
- SGD: один объект, шаг $O(d)$; очень быстрые шаги, мало памяти, но шумно, и точно не сходится.
- Mini-batch: b объектов, шаг $O(bd)$; баланс, работает на GPU; ещё один гиперпараметр b .

SGD с постоянным шагом точно в минимум не приходит: шум градиента не затухает, и веса блуждают около минимума. Momentum копит «инерцию» и гасит зигзаги, Adam подбирает свой шаг каждому весу.

Замечание (аналитика или спуск).

	аналитика	спуск
сложность	$O(nd^2 + d^3)$	$O(nd)$ на итерацию
память	вся X и матрица $d \times d$	можно батчами
точность	точный минимум	с точностью ε
гиперпараметры	нет	η , итерации, батч
потери	MSE и Ridge	любые дифференцируемые
когда	d до $\sim 10^4$, данные в памяти	большие n и d , другие потери

§4 Регуляризация

Переобучение — это огромные веса. Полином 15-й степени проходит через все 16 точек, веса доходят до 10^{11} , и модель очень чувствительна к шуму. Идея: штрафовать не только ошибку, но и размер весов.

Def (Ridge, L_2).

$$L(w) = \|Xw - y\|^2 + \lambda\|w\|^2,$$
$$\nabla_w L = 2X^\top Xw - 2X^\top y + 2\lambda w = 0,$$

$$w^* = (X^\top X + \lambda I)^{-1} X^\top y$$

Матрица обратима при любом $\lambda > 0$: при $v \neq 0$

$$v^\top (X^\top X + \lambda I) v = \|Xv\|^2 + \lambda\|v\|^2 > 0.$$

В спуске это weight decay — веса «усыхают» на каждом шаге:

$$w \leftarrow (1 - 2\eta\lambda) w - \eta \nabla \|Xw - y\|^2.$$


Замечание (нормировка). Здесь ошибка — сумма квадратов, без $\frac{1}{n}$. Если брать MSE с $\frac{1}{n}$, в формуле решения вместо λ стоит $n\lambda$.

Def (Lasso, L_1).

$$L(w) = \|Xw - y\|^2 + \lambda \sum_{j=1}^d |w_j|.$$

Зануляет часть весов — автоматический отбор признаков: с ростом λ веса по очереди становятся нулём. Аналитического решения нет: $|w|$ не дифференцируем в нуле. Решают субградиентом или покоординатным спуском. Сумма с $j = 1$: свободный член не штрафуют.

Утверждение (почему L_1 зануляет). Задача со штрафом равносильна минимизации ошибки при ограничении $\|w\| \leq C$. Решение — точка касания линий уровня ошибки с областью. У ромба L_1 углы на осях, касание часто приходится на угол, и один вес равен нулю. У круга L_2 углов нет: веса малы, но не нули.



Замечание (что выбрать). Ridge устойчив, решается формулой, лечит мультиколлинеарность, но признаков не отбирает. Lasso отбирает признаки, модель проще объяснить, но из группы коррелирующих признаков он берёт один случайно. ElasticNet сочетает оба штрафа ценой двух гиперпараметров. λ подбирают на валидации или кросс-валидацией.

§5 Метрики регрессии

$$\text{MAE} = \frac{1}{n} \sum_i |a(x_i) - y_i|,$$

$$\text{MSE} = \frac{1}{n} \sum_i (a(x_i) - y_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}.$$

MAE — «типичная» ошибка, в единицах ответа. MSE удобна для оптимизации, но в квадрате единиц. RMSE снова в единицах ответа, но чувствительна к выбросам.

Пример. Одна большая ошибка меняет всё:

- ошибки 1, 1, 1, 1, 1: $\text{MAE} = \text{MSE} = \text{RMSE} = 1$;
- ошибки 1, 1, 1, 1, 20: $\text{MAE} = 4,8$, $\text{MSE} = 80,8$, $\text{RMSE} \approx 8,99$.

Утверждение (лучшая константа). Если модель обязана предсказывать одно число c , то для MSE лучшее — среднее, для MAE — медиана.

Док-во. Производная $\sum_i (c - y_i)^2$ равна $2 \sum_i (c - y_i)$, ноль при $c = \bar{y}$. Производная $\sum_i |c - y_i|$ равна $\sum_i \text{sign}(c - y_i)$: точек слева минус точек справа. Ноль, когда их поровну, — в медиане. ■

Def (MAPE и SMAPE). Относительная ошибка в процентах:

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{a(x_i) - y_i}{y_i} \right|,$$

$$\text{SMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{2 |a(x_i) - y_i|}{|a(x_i)| + |y_i|}.$$

Ошибка 1 при $y = 1$ — это 100%, при $y = 100$ — всего 1%: удобно сравнивать ряды разного масштаба, продажи хлеба и машин. MAPE взрывается при $y \approx 0$ и несимметрична: занижение даёт не больше 100%, завышение — сколько угодно. При $y = 100$ прогноз $a = 0$ даёт 100%, а $a = 300$ — уже 200%; при $y = 0,01$ прогноз $a = 1$ даёт 9900%. SMAPE ограничена сверху, 200%, но тоже не идеальна.

Def (R^2 , коэффициент детерминации). Сравнение с константой:

$$R^2 = 1 - \frac{\sum_i (a(x_i) - y_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

$R^2 = 1$ — идеальный прогноз, $R^2 = 0$ — не лучше, чем всегда предсказывать среднее, $R^2 < 0$ — хуже константы. От масштаба y не зависит, поэтому удобен для сравнения задач.

§6 Линейная классификация

Def (отступ). Ответы $y_i \in \{-1; +1\}$, прогноз — знак:


$$a(x) = \text{sign}\langle w, x \rangle, \quad M_i = y_i \langle w, x_i \rangle.$$

$M_i > 0$ — ответ верный, $M_i < 0$ — ошибка, $|M_i|$ — уверенность.

Число ошибок — ступенька, её градиент почти везде ноль. Поэтому минимизируют гладкую верхнюю оценку:

$$\frac{1}{n} \sum_i [M_i < 0] \leq \frac{1}{n} \sum_i \tilde{L}(M_i),$$

например логистическую $\log_2(1 + e^{-M})$ или hinge $\max(0, 1 - M)$.



Def (логистическая регрессия). Вероятность класса 1 — сигмоида от $\langle w, x \rangle$:

$$p = \sigma(\langle w, x \rangle), \quad \sigma(z) = \frac{1}{1 + e^{-z}},$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

Log-loss при $y_i \in \{0; 1\}$:

$$L = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)],$$

$$\nabla L = \frac{1}{n} X^\top (\sigma(Xw) - y)$$

Та же форма, что у MSE: признаки, взвешенные ошибкой прогноза.

Def (метрики классификации). Тест на болезнь, 100 человек:

	прогноз: болен	прогноз: здоров
болен	TP = 8	FN = 2
здоров	FP = 10	TN = 80

$$\text{precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \approx 0,44, \quad \text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = 0,8,$$

$$F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \approx 0,57.$$

Precision — какая доля найденных правда больна, recall — какую долю больных нашли, F_1 — их среднее гармоническое. Ассурасу = $88/100 = 0,88$, но модель ошибается чаще, чем кажется: из 18 «больных» 10 здоровы. ROC-AUC — качество ранжирования, от порога не зависит.

Замечание (что важнее). Recall — в тесте на редкую болезнь: пропустить больного хуже, чем поднять ложную тревогу. Precision — в спам-фильтре: нужное письмо в спаме хуже лишнего спама во входящих.